

基于 TD3-PID-VMC 动态混合控制双足轮腿机器人运动优化方法

马晓爽^{1,2}, 李晨龙³, 孙启鸣⁴, 杨青田¹, 沈佳忆¹

1. 无锡学院自动化学院, 江苏 无锡 214105;
2. 微惯性仪表与先进导航技术教育部重点实验室, 江苏 南京 210096;
3. 北京航空航天大学杭州创新研究院, 浙江 杭州 310051;
4. 南京林业大学信息科学技术学院, 江苏 南京 210096

基金项目: 微惯性仪表与先进导航技术教育部重点实验室(B类)开放基金课题(SEU-MIAN-202402); 江苏省高等学校基础科学(自然科学)研究面上项目(24KJB590003); 江苏省产学研合作项目(BY20250869); 国家自然科学基金面上项目(62573033); 浙江省自然科学基金资助项目(LQ24F030012); 无锡市创新创业资金“太湖之光”科技攻关计划(基础研究)项目(K20241043); 无锡学院引进人才科研启动专项经费资助项目(2023r016)

通信作者: 马晓爽, 860293@cw Xu.edu.cn 收稿/录用/修回: 2026-01-13/2026-04-17/

摘要

为实现双足轮腿机器人在复杂地形下的高精度、强鲁棒运动控制, 本文提出一种基于 TD3-PID-VMC 动态混合控制方法。首先, 基于对称式四连杆闭环结构设计并构建双足轮腿机器人运动学模型, 实现轮式滚动与腿式支撑的协同控制; 其次, 引入设定值加权策略改进串级比例-微分-积分(PID)控制器以提升轮毂电机的快速响应与稳态转速调节能力, 并利用虚拟模型控制(VMC)优化系统模型参数, 从而增强运动性能与环境适应性; 最后, 设计双延迟深度确定性策略梯度(TD3)驱动的混合权重动态分配模块, 通过强化学习离线训练获得最优融合策略, 并在实际控制中在线部署, 实现 PID 与 VMC 权重的动态自适应调整, 以适应不同地形和运动状态的需求。仿真与实物实验结果表明, 在多模式轨迹跟踪任务中, 本文方法的均方根误差(RMSE)较固定权重 PID-VMC 方法和 LQR-VMC 方法分别降低约 32.9% 和 28.7%, 在突发冲击扰动下恢复时间小于 3.2s。本文方法有效提升了双足轮腿机器人在静态平衡、抗扰恢复与轨迹跟踪任务中的稳定性与精度。

关键词

PID 控制
虚拟模型控制
TD3 强化学习算法
双足轮腿机器人
中图分类号: TP242.6
文献标志码: A

Motion Optimization Method for Bipedal Wheel-legged Robots Based on TD3-PID-VMC Dynamic Hybrid Control

MA Xiaoshuang^{1,2}, LI Chenlong³, SUN Qiming⁴, YANG Qingtian¹, SHEN Jiayi¹

1. School of Automation, Wuxi University, Wuxi Jiangsu 214105, China;
2. Key Laboratory of Micro-Inertial Instrument and Advanced Navigation Technology, Ministry of Education, Nanjing, Jiangsu 210096, China;
3. Hangzhou Innovation Institute, Beihang University, Hangzhou, Zhejiang 310051, China;
4. School of Information Science and Technology, Nanjing Forestry University, Nanjing, Jiangsu 210037, China

Abstract

To achieve high-precision and robust motion control for bipedal wheel-legged robots on complex terrains, we propose a TD3-PID-VMC dynamic hybrid control method. First, based on a symmetric four-link closed-loop structure, the kinematic model of the bipedal wheel-legged robot is designed and constructed to achieve coordinated control of wheel rolling and leg support. Then, a setpoint weighting strategy is introduced to improve the cascade Proportional-Integral-Derivative (PID) controller, enhancing the fast response and steady-state speed regulation capability of the hub motors, while Virtual Model Control (VMC) is utilized to optimize system model parameters, thereby improving motion performance and environmental adaptability. Finally, a hybrid weight dynamic allocation module driven by the twin delayed deep deterministic policy gradient (TD3) algorithm is designed. The optimal fusion strategy is obtained through offline reinforcement learning training and deployed online in real-world control, enabling dynamic and adaptive adjustment of the PID and VMC weights to accommodate diverse terrains and motion states. Simulation and hardware experimental results demonstrate that in multi-mode trajectory tracking tasks, the proposed method reduces the root mean square error (RMSE) by approximately 32.9% and 28.7% compared to the fixed-weight PID-VMC method and the LQR-VMC method, respectively, with a recovery time of less than 3.2 s under sudden impact disturbances. The proposed method effectively enhances the stability and precision of the bipedal wheel-legged robot in static balance, disturbance recovery, and trajectory tracking tasks.

Keywords

PID control;
virtual model control;
TD3 reinforcement learning
algorithm;
bipedal wheel-legged robot

0 引言

随着机器人技术的快速发展,双足轮腿机器人因其兼具轮式机器人的高效移动能力与腿式机器人的强地形适应性,在复杂环境下的应用潜力日益凸显^[1-3]。然而,由于运动模式的多样性与环境的不确定性,该类机器人在实际应用中仍面临运动稳定性不足、关节控制精度欠佳等挑战^[4-5]。特别是在动态环境下,传统控制方法往往难以兼顾快速响应能力与鲁棒性,导致机器人运动性能下降,甚至失稳^[6-8]。研究表明,这些挑战源于双足轮腿机器人固有的三重核心矛盾:轮式高速连续运动与腿式间歇稳定支撑之间的“模态冲突”、连续旋转关节与间歇冲击负载关节之间的“动力学耦合”,以及在不确定环境下模型精度与响应速度之间的“性能权衡”^[9]。因此,研究一种高效、稳定的关节运动优化方法,对提升双足轮腿机器人的环境适应能力具有重要意义。

目前,双足轮腿机器人的控制策略主要分为基于模型的控制和无模型控制2类。传统比例-微分-积分(PID)控制因其结构简单、易于实现,被广泛应用于关节运动控制,但其在非线性、强耦合系统中的参数整定困难,动态性能受限^[10]。虚拟模型控制(VMC)通过构建虚拟力学模型简化控制问题,能够有效提升机器人的运动适应性,但对模型精度依赖较高,且在快速响应方面存在不足^[11-12]。为融合

二者优势,混合控制策略逐渐成为研究热点。例如,Liu Dandan等^[13]提出将VMC与线性二次型调节器(LQR)结合用于双足轮腿机器人的平衡控制,在结构化环境中取得了良好效果,验证了模型驱动混合控制的潜力。李宇等^[14]则尝试将串级PID与VMC进行固定权重融合,也验证了混合架构在提升系统鲁棒性方面的潜力。然而,其权重分配机制仍存在2个核心瓶颈:其一,基于启发式规则(如速度阈值)的静态或半静态分配难以适应动态、非结构化的复杂环境;其二,参数整定高度依赖专家经验与试错,缺乏对未知扰动与多变地形的在线自适应能力^[15]。这导致现有混合方法在应对前述“模态冲突”与“动力学耦合”时策略固化,从而在机器人面临突发扰动、复杂地形或运动模式频繁切换时,控制性能显著下降。

为突破上述基于固定规则的混合控制框架的局限,强化学习在机器人运动控制领域展现出强大的优化能力,为解决此类动态权衡问题提供了全新思路^[16-17]。以双延迟深度确定性策略梯度(twin delayed deep deterministic policy gradient, TD3)算法为代表的深度强化学习方法,通过双重Critic(评论家)网络、延迟策略更新和目标策略平滑机制,有效解决了传统深度确定性策略梯度(DDPG)算法的价值函数过估计问题,在连续控制任务中表现出优异的稳定性和收敛性,使其成为机器人运动控制的理想选

择^[18]。已有学者尝试将强化学习应用于机器人控制优化, 但现有工作主要集中于 2 类: 一是利用强化学习对单一控制器(如 PID)的内部参数进行在线自整定^[19]; 二是构建完全由数据驱动的“端到端”控制策略, 以强化学习直接输出底层控制指令^[20]。前者未能突破单一控制器的性能上限, 后者虽灵活但可解释性差、训练成本高, 且未能与可靠的模型驱动控制方法相结合, 在安全关键场景(如动态避障、抗冲击恢复)中可能因缺乏稳定性保障与可验证性而引发失控风险。因此, 目前尚缺乏一套系统的框架, 能够将强化学习的自适应决策能力, 深度、结构化地嵌入到 PID 与 VMC 等传统混合控制架构中, 以构建一个面向双足轮腿机器人核心矛盾、兼具智能性与可靠性的在线权重决策层。

针对上述问题, 本文提出一种基于 TD3-PID-VMC 动态混合控制方法。该方法构建了分层控制架构: 底层由改进串级 PID 与 VMC 构成混合执行层, 保障基础控制性能; 上层引入 TD3 算法, 通过离线训练学习混合权重的通用分配策略, 并在线部署为实时决策层, 实现 PID 与 VMC 权重的动态自适应优化。

1 基于四连杆机构的双足轮腿机器人运动学建模

本文双足轮腿机器人整体采用对称式设计, 每条腿均为独立四连杆闭环机构, 并且通过关节电机驱动主动连杆实现腿长动态调整。该机器人结合轮毂电机的连续旋转动力, 实现了轮式滚动与腿式支撑的混合运动模式。在此基础上, 利用几何约束优化方法求解运动学正逆问题, 建立了腿长与各关节角度之间的函数关系, 从而实现平滑的运动轨迹。

1.1 四连杆机构参数化设计

四连杆机构单腿 2 维平面图绘制如图 1 所示, 其由主动连杆(AD)、从动连杆(CD)、底部连杆




图 1 四连杆机构单腿 2 维平面图

Fig.1 Two-dimensional plan of a single leg based on four-bar linkage mechanism

(DE)、连接连杆(BE)构成。图 1 中, A 点为关节电机所在位置, C 点为轮毂电机, B 点为从动关节固定点。关节电机离地面高度为 h :

$$h = \frac{2S_{ADC}}{L_{AD}} + r = L_{DC} \times \sin \alpha + r \quad (1)$$

其中, S_{ADC} 为主动连杆与从动连杆 3 个端点 A、C、D 组成的三角形面积; L 为连杆长度; α 为关节角度($\angle ADC$), C、D、E 三点共线; r 为轮毂电机半径。

根据图 1 中的四连杆机构和式 (1) 所述的关系, 各连杆的实际设计参数如表 1 所示。其参数基于实物样机的机械设计确定, 当关节角度 α 在 $30^\circ \sim 90^\circ$ 范围内变化时, 机体可实现离地高度在 120 ~ 280 mm 范围内连续调节, 且具有单调递增特性, 满足双足轮腿机器人在不同地形下的间隙适应性与运动稳定性需求。

表 1 四连杆机构主要尺寸参数

Tab.1 Main dimensional parameters of the four-bar linkage

参数符号	物理含义	数值(mm)	备注
L_{AD}	主动连杆长度	150	关节电机驱动
L_{CD}	从动连杆长度	210	连接轮毂中心与D点
L_{DE}	底部连杆长度	40	支撑轮毂与机体结构
L_{BE}	连接连杆长度	100	保持四连杆闭环几何约束
r	轮毂半径	50	轮毂电机外径
h	离地高度	120 ~ 280	对应 $\alpha = 30^\circ \sim 90^\circ$

1.2 双足轮腿机器人运动学建模与分析

1.2.1 正运动学建模

本节建立双足轮腿机器人腿部四连杆机构的完整正运动学模型。以主动关节 A 点为坐标系原点建立 X-Y 2 维平面坐标系。基于几何约束条件, 推导出系统的运动学方程组^[21]。

首先确定主动关节 D 点的位置坐标为

$$(x_D, y_D) = (L_{AD} \cdot \cos \alpha, L_{AD} \cdot \sin \alpha) \quad (2)$$

轮毂中心 C 点需满足从动连杆长度约束条件:

$$(x_C - x_D)^2 + (y_C - y_D)^2 = L_{CD}^2 \quad (3)$$

考虑底部连杆和轮毂半径的影响, C 点垂直坐标需满足:

$$y_C = y_D + L_{DE} \cdot \sin \alpha + r \quad (4)$$

引入连接连杆 BE 约束后, 形成完整的四连杆闭合条件:

$$\begin{cases} (x_C - x_B)^2 + (y_C - y_B)^2 = L_{BE}^2 \\ (x_C - x_D)^2 + (y_C - y_D)^2 = L_{CD}^2 \end{cases} \quad (5)$$

通过联立方程求解 C 点坐标, 最终得到轮毂运动轨迹随着关节角度变化的参数式方程, 采用数值计算方法绘制出 C 点轨迹曲线, 表明轮毂在垂直和水平方向上的动态调整范围。

1.2.2 逆运动学建模

本节进一步建立腿部四连杆机构的逆运动学模型。给定轮毂中心目标位置 $C_{\text{target}}(x_{C_i}, y_{C_i})$, 反求主动关节角度 α 的解析解。基于正运动学分析结果, 逆运动学问题转化为求解非线性方程组:

$$\begin{cases} L_{AD} \cdot \cos \alpha + L_{CD} \cdot \cos \rho = x_{C_i} \\ L_{AD} \cdot \sin \alpha + L_{CD} \cdot \sin \rho = y_{C_i} - r \end{cases} \quad (6)$$

其中, ρ 表示从动连杆 CD 与水平方向的夹角。

通过代数消元法消除中间变量 ρ , 将方程组简化为关于 α 的一元非线性方程:

$$(x_{C_i} - L_{AD} \cdot \cos \alpha)^2 + (y_{C_i} - r - L_{AD} \cdot \sin \alpha)^2 = L_{CD}^2 \quad (7)$$

利用三角恒等式即可求解得主动关节角度 α 。

2 动态混合控制架构设计

针对双足轮腿机器人多模态运动控制需求, 本文设计了一种基于 TD3-PID-VMC 的动态混合控制架构。该架构通过有机结合改进 PID 控制器的快速响应与 VMC 的动态补偿优势, 构建了具有 3 层结构的智能控制系统: 1) 底层的改进 PID 执行单元实现电机精准控制; 2) 中层的 VMC 模块提供模型补偿; 3) 上层的动态融合机制实现控制策略优化。下文将分别详细阐述各关键模块的设计原理与实现方法。

2.1 轮式平衡改进 PID 控制器设计

本部分提出一种改进的串级 PID 控制器架构, 其原理图如图 2 所示。其中, 外环位置 PID 控制器

根据系统输出与期望值的偏差, 生成内环控制器的设定值, 主要负责关节角度跟踪控制, 内环速度 PID 控制器则快速跟踪这一设定值, 通过双重闭环调节有效抑制系统扰动实现动态响应调节^[22-23]。

为避免目标位置阶跃信号引起的微分冲击, 外环位置控制器引入设定值加权策略, 采用微分先行 (即设定值微分权重 $\gamma=0$) 以消除设定值阶跃变化时的微分冲击, 同时引入比例项设定值权重 $\beta (0 < \beta < 1)$ 以软化控制指令, 实现对目标位置的平滑过渡。与现有研究中侧重于参数自整定的串级 PID 改进方法不同, 本文的改进聚焦于指令预处理层面。具体而言, 通过设定值加权策略直接柔化外环指令, 旨在从源头抑制双足轮腿机器人关节在模式切换或轨迹跟踪中因指令突变引发的冲击与振荡, 而非泛化地提升参数适应性。该设计是出于对特定被控对象 (轮毂电机) 动态特性与整体混合控制架构对底层响应平稳性要求的针对性考量, 为后续 TD3 驱动的权重优化提供了稳定、可靠的控制基底。

外环位置控制器根据位置误差 $e(t)$ 生成速度设定值:

$$\begin{aligned} v_{\text{ref}} = & K_{p1} [\beta \cdot X_{\text{ref}}(t) - X(t)] \\ & + K_{i1} \int_0^t [X_{\text{ref}}(t) - X(t)] dt \\ & + K_{d1} \left[\gamma \cdot \frac{dX_{\text{ref}}(t)}{dt} - \frac{dX(t)}{dt} \right] \end{aligned} \quad (8)$$

其中, $X_{\text{ref}}(t)$ 为期望目标位置; $X(t)$ 为实际位置; v_{ref} 为外环控制器输出 (内环速度设定值); K_{p1} 、 K_{i1} 、 K_{d1} 为外环 PID 参数。

内环速度控制器跟踪速度设定值:

$$\begin{aligned} u(t) = & K_{p2} (v_{\text{ref}} - v) \\ & + K_{i2} \int_0^t (v_{\text{ref}} - v) dt + K_{d2} \frac{d(v_{\text{ref}} - v)}{dt} \end{aligned} \quad (9)$$




图 2 串级 PID 控制原理图

Fig.2 Schematic diagram of cascade PID control

其中, v 为当前速度值, $u(t)$ 为控制器输出(电机驱动指令); K_{p2} 、 K_{i2} 、 K_{d2} 为内环 PID 参数。

为保障系统的快速性与稳定性, 采用改进的 Ziegler-Nichols 方法整定 PID 参数。已知系统临界频率 ω_c 和临界响应特性 $G(j\omega_c)$, 基于系统在临界状态下的振荡特性, 获取临界增益 K_u 和临界周期 T_u :

$$K_u = 1/|G(j\omega_c)| \quad (10)$$

$$T_u = 2\pi/\omega_c \quad (11)$$

通过将奈氏图上的临界点 $G(j\omega_c)$ 移到目标位置(即幅值为 A_m 且相位为 $(-\pi + \Phi_m)$ 的点), 整定 PID 参数如下:

$$K_p = K_u \cos \Phi_m / A_m \quad (12)$$

$$K_i = \pi K_u \cos^2 \Phi_m / [A_m T_u (1 + \sin \Phi_m)] \quad (13)$$

$$K_d = K_u T_u (1 + \sin \Phi_m) / (4\pi A_m) \quad (14)$$

其中, A_m 为期望幅值裕度, Φ_m 为期望相位裕度, K_u 为临界增益, T_u 为临界周期。由以上公式可知, 确定系统的 A_m 和 Φ_m 就能够得到整定后的 PID 参数。需要说明的是, 整定过程中所使用的临界频率 ω_c 与临界增益 K_u 等关键参数, 均基于实物机器人平台的开环阶跃响应实验获取, 确保了控制器设计与真实系统动态特性的一致性。

2.2 腿部关节 VMC 动态补偿器设计

VMC 通过构建虚拟力学元件对机器人腿部的运动行为进行仿生控制, 实现对机器人腿部运动状态的精确调节与柔性响应^[19]。

在机器人腿部末端与目标轨迹之间建立虚拟弹簧-阻尼系统, 其产生的虚拟力为

$$\mathbf{F}_{\text{virtual}} = K_v(\mathbf{x}_{\text{target}} - \mathbf{x}) + K_d(\mathbf{v}_{\text{target}} - \mathbf{v}) + \mathbf{F}_{\text{offset}} \quad (15)$$

其中, K_v 和 K_d 分别为虚拟弹簧刚度和虚拟阻尼系数; $\mathbf{x}_{\text{target}}$ 和 $\mathbf{v}_{\text{target}}$ 分别为目标位置和目标速度; $\mathbf{x}$ 和 $\mathbf{v}$ 为当前位置和速度; $\mathbf{F}_{\text{offset}}$ 为重力、外部扰动或补偿项。

通过腿部的雅可比矩阵转置将虚拟力转换为关节力矩:

$$\boldsymbol{\tau}_{\text{VMC}} = \mathbf{J}^T \mathbf{F}_{\text{virtual}} \quad (16)$$

其中, $\mathbf{J}$ 为腿部运动学雅可比矩阵。

VMC 的核心在于确定适当的虚拟弹簧刚度 K_v 和阻尼系数 K_b 。针对双足轮腿机器人支撑阶段、摆动阶段等不同工作状态下的动态行为, 采用差异化参数策略进行动态规划和自适应调节。将单腿动力学模型简化为 1 维垂直方向运动系统, 忽略横向耦合效应。在该模型中, 腿部所受合力由以下 4 个分力构成:

$$\mathbf{F}_T = \mathbf{F}_{\text{VMC}} + \mathbf{F}_K - \mathbf{F}_D - \mathbf{F}_G \quad (17)$$

其中, $\mathbf{F}_{\text{VMC}}$ 为虚拟模型控制力; $\mathbf{F}_K$ 为弹簧力; $\mathbf{F}_D$ 为阻尼力; $\mathbf{F}_G$ 为重力。

采用 PD 控制器结合弹簧阻尼补偿的混合策略来实现:

$$\mathbf{F} = K_p \mathbf{e} + K_d \dot{\mathbf{e}} + K_v \mathbf{x} - K_b \mathbf{v} \quad (18)$$

其中, K_p 与 K_d 分别为控制器的比例与微分增益, $\mathbf{e}$ 与 $\dot{\mathbf{e}}$ 分别为位置跟踪误差及其微分。

该策略通过 PD 控制器实现误差的快速反馈调节, 并引入基于模型的前馈项 $K_v \mathbf{x} - K_b \mathbf{v}$ 对系统固有动力学特性进行主动补偿。二者协同作用, 可在保证系统稳定性和响应速度的同时, 进一步提高轨迹跟踪精度。

2.3 PID-VMC 动态融合机制

为实现 PID 控制器与 VMC 模块的协同控制, 设计了基于运动状态的自适应融合机制。该机制根据机器人当前运动速度与地形特征, 动态调整 PID 与 VMC 的权重分配, 实现控制策略的平滑切换与优势互补。

融合后的输出关节力矩定义为:

$$\boldsymbol{\tau}_{\text{hybrid}} = a_{\text{PID}} \cdot \boldsymbol{\tau}_{\text{PID}} + a_{\text{VMC}} \cdot \boldsymbol{\tau}_{\text{VMC}} \quad (19)$$

其中, $\boldsymbol{\tau}_{\text{PID}}$ 与 $\boldsymbol{\tau}_{\text{VMC}}$ 分别为 PID 控制器与 VMC 模块输出的关节力矩; a_{PID} 与 a_{VMC} 为对应的动态权重系数, 满足归一化约束:

$$a_{\text{PID}} + a_{\text{VMC}} = 1, \quad 0 \leq a_{\text{PID}}, a_{\text{VMC}} \leq 1 \quad (20)$$

权重系数根据机器人当前运动速度 v 进行动态调整, 采用 Sigmoid 型函数实现平滑过渡:

$$a_{\text{PID}} = 1 / (1 + e^{-\mu(v - v_{\text{th}})}) \quad (21)$$

$$a_{\text{VMC}} = 1 - a_{\text{PID}} \quad (22)$$

其中, v_{th} 为轮式与腿式运动模式切换阈值; μ 为平滑系数, 控制权重变化曲线的陡峭程度。

式 (21)、(22) 所描述的基于速度阈值的 Sigmoid 权重分配为基础融合规则, 代表了一种典型的基于启发式规则的静态权重分配方法。这类方法因其设计简单、实现直观而被广泛应用。然而, 其在双足轮腿机器人这类多模态、强耦合的动态系统中存在决策维度单一、策略固化、泛化能力弱等固有局限。

为此, 本文第 3 节引入 TD3 强化学习算法, 构建智能决策层以实现权重系数的动态优化。这标志着权重分配问题从基于经验的、离线的规则设计, 转向了基于数据的、可在线自适应的序列决策优化, 旨在实现控制系统在动态复杂环境下的更高阶智能。需要指出的是, 上述 2 种融合机制采用“主

备切换”策略：TD3 策略网络作为主控制器实时输出最优权重，当检测到推理超时或传感器异常时自动切换至式 (21)、(22) 的规则层。

此外，该机制使闭环系统呈现非线性时变特性，其严格的稳定性理论分析(如基于李雅普诺夫方法)目前仍具挑战性。因此，本文的贡献聚焦于工程方法学：我们提出并通过大量实验验证了这一数据驱动与模型控制相协同的框架在提升双足轮腿机器人运动性能上的有效性。理论层面的深入分析将是未来的重要工作。

3 基于 TD3 强化学习的控制参数优化方法

为实现 PID-VMC 混合控制权重的动态自适应优化，本节构建基于 TD3 强化学习的闭环优化框架，其核心要素(状态、动作、奖励)的设计均源于对双足轮腿机器人运动控制物理本质的考量。

3.1 状态空间、动作空间与奖励函数设计

将机器人的运动状态向量 s_t 定义为包含质心姿态角(俯仰角 θ 、横滚角 φ)、关节角度 q 与角速度 $\dot{q}$ 、机器人质心合速度 v 、足端接触力 F_c 及地形粗糙度估计参数 η 的多维观测向量：

$$s_t = [\theta, \varphi, q, \dot{q}, v, F_c, \eta] \quad (23)$$

其中，地形粗糙度估计参数 η 基于地面距离测量值与机体姿态变化率经卡尔曼滤波融合得到，用于表征地面不平整程度，取值范围 $[0,1]$ (0 为完全平坦，1 为崎岖地形)^[25]。仿真环境中采用相同定义，基于地形高度场点云计算相对标准差，并添加匹配实物噪声水平的高斯噪声，以保障仿真与实物输入分布的一致性。

动作输出定义为 PID-VMC 混合权重向量 $a_t = [a_{PID} \ a_{VMC}]$ ，权重系数需满足如式 (20) 所示的归一化约束。该权重输出直接对应式 (19) 中的 a_{PID} 与 a_{VMC} ，可在部署阶段覆盖本文 2.3 节所述的基础 Sigmoid 权重规则，实现基于强化学习的动态优化分配。

为平衡双足轮腿机器人运动的稳定性、能效性与跟踪精度，设计多目标复合奖励函数：

$$r_t = \omega_1 r_{\text{stability}} + \omega_2 r_{\text{tracking}} + \omega_3 r_{\text{energy}} + \omega_4 r_{\text{smooth}} \quad (24)$$

其中，稳定性奖励 $r_{\text{stability}} = \exp(-\lambda_1 |\theta| - \lambda_2 |\varphi|)$ ，采用指数形式对大幅姿态偏差施加严厉惩罚，其敏感系数 λ_1 、 λ_2 根据机器人静稳定裕度设定；跟踪奖励 $r_{\text{tracking}} = -\|q^{\text{desired}} - q^{\text{actual}}\|_2$ ， $\|\cdot\|_2$ 表示向量范数，直接激励关节角度精确跟踪；能效奖励 $r_{\text{energy}} = -\|\tau \cdot \omega\|_1$ ，

通过惩罚瞬时功率鼓励节能运动；平滑性奖励 $r_{\text{smooth}} = -\|a_t - a_{t-1}\|_2$ ，保证控制策略连续平滑；各子奖励的权重系数 $\omega_1 \sim \omega_4$ 并非任意设定，而是通过预实验的灵敏度分析确定。各子项权重的确定遵循系统性原则：首先，根据任务安全需求确定稳定性为最高优先级(ω_1 最大)；其次，将各子项奖励值归一化至相近量纲；最后，通过仿真实验调整 $\omega_1 \sim \omega_4$ ，在确保跟踪精度的同时，寻求能效与平滑性的最佳平衡。第 4 节的实验结果验证了该设计下策略的综合性能。

3.2 TD3 算法适应性改进与训练流程

为突破第 2.3 节所述的传统固定规则融合方法的局限，本文引入 TD3 强化学习算法，构建一个数据驱动的智能权重决策层。本方法采用“离线训练、在线部署”的实现策略。TD3 算法首先在仿真环境中进行充分的离线训练，学习 PID 与 VMC 混合权重的动态分配策略；训练完成后，将收敛的策略网络部署至实体机器人，在实际运行中以前馈方式实时输出最优权重，实现基于状态的在线自适应决策。

相较于传统基于单一变量(如速度)的固定规则映射，TD3 策略网络能够综合处理包含姿态、关节状态、接触力及地形估计在内的多维观测信息，从而捕捉更丰富的环境与运动耦合关系。同时，通过复合奖励函数的引导，TD3 能够在离线训练中自主学习如何权衡稳定性、跟踪精度、能效等多目标要求，生成超越人工经验设计的优化策略。训练完成的策略网络部署后，可根据实时状态进行快速前馈计算，使系统在面对未经预编程的真实动态扰动与地形变化时，仍能表现出优异的自适应与泛化能力。

为将 TD3 算法有效应用于双足轮腿机器人的混合控制权重优化，需针对机器人系统的动态特性与控制实时性要求，对标准 TD3 算法进行针对性改进。这些改进并非通用的算法调优，而是紧密围绕机器人系统的动态特性、实时性约束与安全要求而设计，以确保智能决策层与本控制框架的深度契合。改进后的网络结构设计、训练流程设计以及在线部署策略如下所示。

1) 满足实时性与输出约束的轻量化 Actor 网络结构。为确保智能决策能在 10 ms 的控制周期内完成，Actor 策略网络 $\pi_{\omega}(s)$ 采用精简的双层全连接结构，输入层维度与状态向量 s_t 维度一致，隐藏层采用 128 个神经元，激活函数为 ReLU，旨在平衡模型表达能力与实时计算效率。输出层为 2 个神经

元, 对应原始输出值 z_1 与 z_2 。为严格满足混合控制中权重系数需归一化的物理约束(式 (20)), 采用 Softmax 函数进行后处理:

$$a_{\text{PID}} = \frac{e^{z_1}}{e^{z_1} + e^{z_2}}, a_{\text{VMC}} = \frac{e^{z_2}}{e^{z_1} + e^{z_2}} \quad (25)$$

该设计确保输出权重非负且和为 1, 可直接用于混合控制力矩计算。

2) 提升学习效率与稳定性的 Critic 网络结构。定义 2 个 Critic 价值网络为 $Q_{\psi_1}(s, a)$ 和 $Q_{\psi_2}(s, a)$, 其参数分别为 ψ_1 和 ψ_2 。采用双重 Critic 网络结构以缓解价值函数过估计问题。Critic 网络输入为状态 s_t 与动作 a_t 的拼接向量。为提升特征提取效率并减少参数冗余, 2 个 Critic 网络共享前 2 层的特征提取网络(维度分别为 256 和 128), 之后分为 2 个独立的输出分支, 各输出一个 Q 值估计。此设计既可通过参数共享提升学习效率, 又能通过双重估计有效缓解价值函数过估计问题, 是 TD3 算法提升训练稳定性的核心机制。目标网络(Target Actor 及 Target Critic)以软更新方式跟踪主网络参数。

3) 目标策略平滑正则化。在更新 Critic 网络时, 对目标 Actor 网络输出的动作添加截断的零均值高斯噪声 $\varepsilon \sim \text{clip}(N(0, \sigma), -c, c)$, 其中 c 为噪声截断阈值。该操作等效于在目标 Q 值中引入正则化项, 可有效平滑值函数估计, 防止因函数近似误差导致的策略更新发散。

4) 基于机器人控制目标的经验参数设置。策略在仿真环境中进行离线训练, 关键训练参数在 TD3 通用经验值基础上进行了针对性调整, 以匹配机器人控制任务的特性。Actor 与 Critic 学习率均设为 3×10^{-4} , 以平衡收敛速度与稳定性。折扣因子 $\gamma = 0.99$ 促使策略关注长期稳定性, 符合机器人持续运动的需求。探索噪声采用 Ornstein-Uhlenbeck 过程, 其相关性更适合物理系统的惯性特性, 噪声方差从初始的 $\sigma = 0.2$ 随训练线性衰减至 0.05, 以平衡探索与利用。经验回放池容量为 10^6 , 采样批量大小为 256。为保障实验可重复性, 所有训练使用固定的随机种子。策略经过总共 2.0×10^6 步的训练后, 其回合奖励曲线趋于稳定, 表明策略已收敛。训练完成的策略网络被冻结并部署到实体机器人进行后续所有实验。

训练流程在仿真环境中进行, 并针对机器人连续控制任务的特点进行优化。完整的改进 TD3 训练流程如算法 1 所示, 其核心包括经验回放、延迟策略更新和软更新机制。

算法1 适用于PID-VMC权重优化的改进TD3算法

输入: 初始化Actor网络参数 ω , Critic网络参数 ψ_1, ψ_2 , 目标网络参数 $\omega' \leftarrow \omega, \psi'_1 \leftarrow \psi_1, \psi'_2 \leftarrow \psi_2$, 经验回放缓冲区 D , 设定最大训练步数 T , 探索噪声参数 σ , 策略延迟更新频率 d

输出: 优化后的策略网络参数 ω

```

1: for  $t=1$  to  $T$  do
2:   根据当前策略及探索噪声选择动作:
      $a_t \leftarrow \text{clip}(\pi_\omega(s_t) + \varepsilon, 0, 1), \varepsilon \sim N(0, \sigma)$ 
3:   在仿真环境中执行动作  $a_t$ , 观测奖励  $r_t$  和下一状态  $s_{t+1}$ 
4:   将经验元组  $(s_t, a_t, r_t, s_{t+1})$  存入缓冲区  $D$ 
5:   if 达到更新周期 then
6:     从  $D$  中随机采样一个小批次数据  $B$ 
7:     for 每个样本 in  $B$  do
8:       计算目标动作:
          $\tilde{a} \leftarrow \text{clip}(\pi_{\omega'}(s') + \varepsilon, 0, 1), \varepsilon \sim \text{clip}(N(0, \sigma), -c, c)$ 
9:       计算目标  $Q$  值:  $y \leftarrow r + \gamma \min_{i=1,2} Q_{\psi'_i}(s', \tilde{a})$ 
10:    end for
11:    更新Critic网络:
        $\psi_i \leftarrow \arg \min_{\psi_i} \frac{1}{|B|} \sum (y - Q_{\psi_i}(s, a))^2, i = 1, 2$ 
12:    if  $t \bmod d$  then
13:      通过确定性策略梯度更新Actor网络:
          $\nabla_\omega J \approx \frac{1}{B} \sum \nabla_a Q_{\psi_1}(s, a)|_{a=\pi_\omega(s)} \nabla_\omega \pi_\omega(s)$ 
14:      软更新目标网络:
          $\omega' \leftarrow \tau \omega + (1 - \tau) \omega', \psi'_i \leftarrow \tau \psi_i + (1 - \tau) \psi'_i$ 
15:    end if
16:  end if
17: end for

```

训练完成的策略网络 $\pi_{\omega^*}(s)$ (其中 ω^* 为训练收敛后的参数) 被部署到实体机器人。在每个控制周期内, 网络读取当前状态 s_t , 通过前向传播瞬时计算出最优混合权重 a_t , 指导底层 PID-VMC 混合控制器。为保障系统安全, 输出权重限幅于 $[0, 1]$ 区间, 并设有超时监控机制; 一旦检测到状态异常或计算超时, 系统将自动切换至第 2.3 节式 (21)、(22) 描述的固定权重后备规则层。

3.3 训练收敛性分析

为验证 TD3 策略网络的训练效果, 本节分析其收敛特性。训练共执行 100 个回合(对应总步数

2.0×10^6 步, 每 2.0×10^4 步为 1 个回合), 每回合记录一次平均回合奖励与 Critic 网络 Q 值估计, 结果如图 3 所示。

图 3(a) 为平均回合奖励曲线。训练初期(0~20 回合), 由于策略以随机探索为主, 与环境交互的试错成本较高, 平均回合奖励由 -1.7×10^4 快速下降至 -2.3×10^4 , 曲线呈现较大波动。随着经验回放池中优质样本的累积与策略迭代优化, 20~80 回合区间内平滑后的奖励曲线趋于稳定, 波动幅度显著收窄。训练后期(80~100 回合), 平均回合奖励收敛至 $-2.3 \times 10^4 \pm 5 \times 10^2$, 表明策略已学习到稳定的决策模式。

图 3(b) 为 Critic 网络 Q 值估计曲线。得益于 TD3 算法的双重 Critic 架构与目标策略平滑正则化, Q_1 与 Q_2 网络的估计值始终保持高度一致, 未出现 DDPG 算法中常见的价值过估计发散现象。训练初期(0~20 回合), Q 值由约 -20 快速下降至 -350, 反映了 Critic 网络对状态-动作价值的快速校准; 20 回合后, Q 值曲线进入平稳阶段, 振荡幅度较训练中期减小约 60%, 进一步验证了策略网络已进入稳定收敛状态。

3.4 系统总体框架

为清晰展示本文所提方法的整体框架与工作流程, 图 4 给出了基于 TD3 强化学习的 PID-VMC 混合控制系统总体架构。该架构包含 2 个主要阶段:

1) 强化学习训练阶段(上部): 在仿真环境中, TD3 算法通过与环境的交互收集数据, 并存储至经验回放池, 通过 Critic 网络评估价值并优化 Actor 策略网络参数, 最终得到训练收敛的策略网络 $\pi_{\omega^*}(s)$ 。

2) 在线控制阶段(下部): 在实际控制中, 多源传感器信息构成状态向量 s_t , 由训练好的策略网络实时输出混合权重 $[a_{PID} \ a_{VMC}]$, 指导 PID 控制器与 VMC 模块进行动态融合, 生成关节力矩 τ_{hybrid} 驱动机器人, 形成“感知-决策-控制”闭环。

4 样机测试与实验分析

为验证本文所提基于 TD3-PID-VMC 动态混合控制方法的有效性与优越性, 搭建了双足轮腿机器人实验平台, 并引入了传统 PID-VMC 固定权重方法、LQR-VMC 混合控制方法作为对比, 同时考虑了多源干扰的影响。通过关节运动与抗扰性能测试




图 3 TD3 策略网络训练收敛曲线

Fig.3 Training convergence curves of TD3 policy network




图4 系统总体架构框图

Fig.4 Block diagram of the overall system architecture

与分析、轨迹跟踪控制实验两部分, 验证所提方法在双足轮腿机器人控制中的有效性。

4.1 实验平台与配置

实物样机采用自主研发的“BWR-II”双足轮腿机器人平台, 搭载 STM32H743 作为底层电机控制器, 负责执行高频率(500 Hz)的电流环与速度环控制; 上位机采用 Intel NUC 11 运行 ROS 与 TD3 策略网络, 实现 10 ms 周期的决策与控制闭环。上层与底层通过 CAN 总线(1 Mb/s)进行实时数据交换, 端到端延迟 <2 ms。所有控制算法均通过硬件在环(HIL)仿真验证后, 方部署至实物系统, 确保了软件与硬件的兼容性、实时性与可靠性。

4.2 关节运动与抗扰性能测试与分析

为系统验证本文所提方法的有效性与鲁棒性, 本节设计了多层次、多工况的关节运动控制实验。在测试工况上, 实验涵盖 3 种腿长配置下的静态平衡恢复, 以及脉冲扰动、持续随机扰动 2 类典型干

扰模式, 覆盖机器人关节运动控制的核心任务场景。本节具体采用腿长切换与抗扰动恢复 2 类实验方案, 评估本文所提基于 TD3-PID-VMC 动态混合控制算法在机器人关节运动控制中的性能。需要说明的是, 本节所施加的扰动信号基于实物平台实测数据建模(脉冲扰动源自跌落冲击实验, 持续扰动源自不平整地面实测), 地形粗糙度参数 η 由传感器在线融合计算, 而非人为设定。

在 3 种腿长配置(120、160、200 mm)下进行了静态平衡恢复测试。机器人从相同的初始倾斜姿态开始, 目标是在不同腿长下自主恢复并保持直立平衡。图 5 展示了在 TD3 优化控制器作用下, 3 种腿长对应的姿态角恢复过程曲线, 实物测试场景如图 6 所示。

实验结果表明, 所提 TD3 优化控制器在不同腿长配置下均能快速、平滑地稳定机器人姿态。随着腿长增加, 系统的惯性矩增大, 稳定时间相应有所




图5 不同腿长配置下的静态平衡姿态角变化曲线

Fig.5 Static balance attitude angle variation curves under different leg length configurations




图6 不同腿长实物测试图

Fig.6 Physical test for different leg lengths

延长,但超调量始终保持在较低水平($<1^\circ$),体现了良好的阻尼特性。更重要的是,控制器并未针对每种腿长进行独立的参数整定,而是依靠训练好的策略网络根据实时状态自动调整控制律,这证明了其强大的参数自适应与泛化能力。

在抗扰动恢复测试中,机器人处于稳定平衡状态(腿长 16 cm)时,于 10 s 施加约 5 N·s 的侧向冲击以模拟突发碰撞、在 25 s 与 35 s 分别施加两段持续的小幅随机扰动以模拟复杂地面或持续外力,观察双足轮腿机器人姿态恢复过程。如图 7 所示,姿态角响应曲线清晰展示了机器人在各类扰动下的快




图7 扰动下姿态恢复过程曲线图

Fig.7 Post-disturbance attitude recovery process curves

速恢复过程与稳定性。

需要说明的是,本节所施加的扰动信号并非理想化数学仿真,而是基于实物平台实测数据建模:脉冲扰动的幅值与持续时间来源于机器人跌落冲击实验的足端接触力实测曲线;持续扰动的频谱特征参考了机器人在不平整地面运行时惯性测量单元(IMU)的实测角速度波动;执行器噪声方差与编码器、IMU 的实测噪声水平严格匹配。因此,本实验的扰动环境具备明确的工程真实性,其对实物系统的参考价值已通过 4.1 节所述的硬件在环(HIL)仿真进一步验证。

测试结果表明,第一次冲击扰动导致最大倾角达 7.8° , TD3-PID-VMC 算法通过快速增大虚拟阻尼至 $15 \text{ N}\cdot\text{s/m}$ 有效抑制振荡,使机器人在 3.2 s 内恢复至平衡状态($\text{Roll} < \pm 1.5^\circ$)。在持续扰动期间,系统保持约 $\pm 2.5^\circ$ 的波动,扰动结束后在 2.8 s 内重新稳定。这充分验证了基于 TD3 强化学习的 PID-VMC 混合控制在应对突发扰动和持续干扰方面的有效性。

上述实验结果表明,本文所提基于 TD3-PID-VMC 混合控制器通过其学习所得的权重调度策略,赋予了双足轮腿机器人 2 项关键能力:对不同机体构形的自适应稳定能力与对突发扰动的智能抑制与快速恢复能力。这验证了将强化学习的决策智能与传统控制方法相结合,在提升机器人基础运动性能方面的有效性。

4.3 双足轮腿机器人位置跟踪控制实验

为综合评估本文所提方法在复杂动态任务中的整体性能及其泛化能力,并验证其在典型混合控制方法中的优势,本节设计了包含多运动模式切换、变速过程及复合干扰的位置跟踪控制实验。为进行全面对比,实验引入了 4 种控制器,纯 PID 控制器、固定权重 PID-VMC 控制器、LQR-VMC 控制器、本文所提 TD3-PID-VMC 控制器。

参考轨迹考虑平坦、不规则、干扰等因素,实验运动轨迹分为 3 个阶段:第 0~3 s 为轮式匀速模式,平滑加速到匀速;第 3~6 s 为轮式变速模式,在基础速度上叠加小幅正弦波动;第 6~10 s 为腿式运动模式,为低频小幅正弦步态。同时,在不同的运动阶段,全面测试抗干扰性能:在第 2、5、8 s 加入脉冲干扰信号模拟突发的外部冲击;利用高斯白噪声模拟执行器固有噪声;利用时变干扰模拟风阻等连续变化的环境扰动。

所有对比方法共享相同的底层控制器结构与核

心参数。串级 PID 控制器参数设定为 $K_{p1} = 60$ 、 $K_{i1} = 10$ 、 $K_{d1} = 6$ (位置环) 及 $K_{p2} = 80$ 、 $K_{i2} = 15$ 、 $K_{d2} = 8$, 并采用设定值加权策略 ($\beta = 0.6$, $\gamma = 0$) 以平滑指令。VMC 参数配置为虚拟弹簧刚度 $K_v = 150 \text{ N/m}$ 与虚拟阻尼系数 $K_b = 25 \text{ N} \cdot \text{s/m}$ 。各方法的本质区别在于混合权重 a_{PID} 与 a_{VMC} 的决策机制: 纯 PID 控制器强制设定为 $[1, 0]$; 固定权重 PID-VMC 控制器依据预设速度阈值 ($v_{\text{th}} = 0.5 \text{ m/s}$, $\sigma = 0.2$) 按 Sigmoid 函数切换; LQR-VMC 控制器采用线性二次型调节器与 VMC 结合, 其状态反馈与权重矩阵通过离线优化得到, 并在实验中保持固定, 该方法代表了基于模型优化但缺乏在线自适应能力的混合控制策略; 本文 TD3 优化 PID-VMC 控制器则通过训练收敛的策略网络 $\pi_{\omega^*}(s)$ 实现基于状态的自适应实时优化。

图 8 展示了 3 种控制器在复合轨迹跟踪任务中的位置跟踪曲线, 表 2 给出了 3 种方法的性能对比结果, 所有结果为 10 次独立重复实验的统计值, 并计算关键性能指标的均方根误差 (RMSE), 其计算公式为




图 8 位置跟踪曲线图

Fig.8 Position tracking curves

表 2 位置跟踪性能对比结果

Tab.2 Comparison results of position tracking performance

方法	RMSE	最大误差	与本文方法对比(p值)
纯PID控制器	0.104 5±0.007 9	0.240 1±0.014 8	$p < 0.001$
固定权重PID-VMC	0.062 1±0.004 9	0.179 8±0.011 9	$p < 0.001$
LQR-VMC	0.058 4±0.004 6	0.171 0±0.011 3	$p < 0.001$
TD3优化PID-VMC	0.041 7±0.003 1	0.152 0±0.009 5	—

注: ***表示 $p < 0.001$, 独立样本 t 检验, $n=10$ 。

$$\text{RMSE}_x = \sqrt{\frac{1}{N} \sum_{k=1}^N (x_{\text{des}}(k) - x_{\text{act}}(k))^2} \quad (26)$$

其中, N 为采样点总数; $x_{\text{des}}(k)$ 为第 k 个采样时刻的期望位置; $x_{\text{act}}(k)$ 为第 k 个采样时刻的实际位置。

实验结果表明, 混合控制架构 (固定权重 PID-VMC、LQR-VMC) 的跟踪精度显著优于纯 PID 控制器, 其 RMSE 分别降低了约 40.4% 和 35.2%。这表明通过融合不同控制方法的优势, 可以有效克服单一控制在复杂任务中的局限性。其中, 基于模型优化的 LQR-VMC 方法表现优于固定权重方法, 验证了模型优化在提升性能方面的作用。TD3-PID-VMC 方法取得了最佳跟踪性能, 其 RMSE 相较于固定权重方法进一步降低了约 32.9%, 相较于 LQR-VMC 方法降低了约 28.7%, 最大跟踪误差也最小。这一提升直接归因于 TD3 策略的网络能够根据实时运动状态动态、非线性地调整混合权重, 而非依赖固定的速度阈值规则。这表明基于学习的智能权重分配策略能更精细、更自适应地调度 2 种控制模式的贡献, 从而实现更优的整体性能与更强的环境泛化能力。

为验证本文方法性能优势的统计显著性, 对 10 次独立重复实验的 RMSE 结果进行独立样本 t 检验。结果表明, 本文方法与 LQR-VMC 方法的差异具有极显著统计学意义 ($p < 0.001$, $t = 8.67$), 与固定权重 PID-VMC 方法的差异同样达到极显著水平 ($p < 0.001$, $t = 8.34$), 与纯 PID 方法的差异亦极显著 ($p < 0.001$, $t = 13.21$)。上述结果证明, 本文方法在轨迹跟踪精度上的提升并非偶然波动, 而是源于动态权重优化策略的实质性改进。

4.4 奖励函数权重灵敏度分析

为验证第 3.1 节奖励函数设计的合理性, 本节对式 (24) 中的关键权重系数 ω_1 (稳定性)、 ω_2 (跟踪精度)、 ω_3 (能效) 进行灵敏度分析。保持其他权重为基准值, 分别将目标权重在 $\pm 50\%$ 范围内变化, 重新训练策略并评估收敛后的平均 RMSE, 结果如图 9 所示。

当 ω_1 降低 50% 时, RMSE 降幅约 13.00%, 表明适度降低稳定性权重可在保证系统稳定的前提下提升跟踪精度; 当 ω_1 增大 50% 时, RMSE 增幅 6.17%, 同时训练收敛速度显著减慢, 说明过度强调稳定性会导致策略性能退化。 ω_2 的增大直接提升跟踪精度, 但超过基准值 50% 后 RMSE 增幅仅约 0.69%, 改善效果趋于饱和, 验证了基准权重的帕累托最优性。 ω_3 的增大可显著降低系统能量消耗




图9 奖励函数权重灵敏度分析

Fig.9 Sensitivity analysis of reward function weights

(约18%),但导致RMSE小幅增加(约7.14%),体现了能效与精度的权衡关系。

综上,本文选取的权重系数在跟踪精度、能量效率与训练稳定性之间取得了良好平衡,使策略能够根据不同运动模式自适应调整。

5 结论

本文提出一种基于TD3-PID-VMC的动态混合控制方法,通过构建运动学模型、设计设定值加权串级PID控制器与VMC模块,并引入TD3算法实现混合权重的动态自适应调整,有效提升了双足轮腿机器人在复杂地形下的运动稳定性与控制精度。

本文的主要贡献包括:提出分层智能控制架构实现数据驱动与模型驱动协同、设计设定值加权策略抑制指令冲击、构建主备切换安全机制保障运行安全。仿真与实物实验结果表明,在多模式轨迹跟踪任务中,本文方法的均方根误差较固定权重PID-VMC方法和LQR-VMC方法分别降低约32.9%和28.7%,在突发冲击扰动下恢复时间小于3.2s,验证了该方法在静态平衡、抗扰恢复与轨迹跟踪任务中的有效性。

未来工作将聚焦于闭环系统稳定性理论分析,以及融合视觉等更多模态感知信息以提升极端环境下的自适应能力。

参考文献

- [1] ZHU QIXIN, GUAN XIKANG, YU BIN, et al. Overview of structure and drive for wheel-legged robots[J]. Robotics and Autonomous Systems, 2024, 181: 104777.
- [2] LIU XUEFEI, SUN YI, WEN SHIKUN, et al. Development of wheel-legged biped robots: a review[J]. Journal of Bionic Engineering, 2024, 21(2): 607-634.
- [3] 张国庆, 崔建峰, 王鑫, 等. 轮腿机器人发展与研究综述[J]. 机器人技术与应用, 2024(2): 14-21.
- [4] KOTHA SWAPNIL SAHA, AKTER NIPA, ABHI SARAFAT HUSSAIN, et al. Next generation legged robot locomotion: a review on control techniques[J]. Heliyon, 2024, 10(18): e37237.
- [5] LIU XUEFEI, SUN YI, HAN QINGFEI, et al. A novel adaptive dynamic optimal balance control method for wheel-legged robot[J]. Applied Mathematical Modelling, 2025, 137(B): 115737.
- [6] XU KANG, WANG SHOUKUN, SHI LEI, et al. Horizon-stability control for wheel-legged robot driving over unknown, rough

- terrain[J]. Mechanism and Machine Theory, 2025, 205: 105887.
- [7] KORAYEM M H, ADRIANI H R. Pursuing a target by wheel-legged mobile robot using NMPC while optimizing obstacles passing[J]. ISA Transactions, 2025, 158: 625-639.
- [8] WEN YAN, LI YING, SHANG QINGYUAN, et al. Wheel-legged SLAM: indoor LiDAR-inertial SLAM integrating kinematic model of wheel-legged robots[J]. IEEE Robotics and Automation Letters, 2025, 10(2): 1273-1280.
- [9] 郭东生, 沈洋林, 张曦元, 等. 一种基于改进 PID 的水下机器人悬停控制方法[J]. 西北工业大学学报, 2025, 43(4): 685-693.
- [10] 梁杰, 专祥涛, 严家政. 基于深度强化学习 TD3 的 PID 参数自整定算法[J]. 武汉大学学报(工学版), 2024, 57(11): 1635-1643.
- [11] YANG JUNZE, WU QIUXUAN, LI SHENAO, et al. Integrated modeling and control optimization of biped wheel-legged robot[J]. IEEE Robotics and Automation Letters, 2025, 10(2): 1465-1472.
- [12] 赵浩阳, 王庆领, 余兰林. 双轮腿机器人动态平衡控制[J/OL]. 控制理论与应用, 2025. <https://kns.cnki.net/kcms2/article/abstract?v=...>
- [13] LIU DANDAN, WANG WEI. Locomotion control of a bipedal wheeled robot using virtual model control and linear quadratic regulator techniques[J]. Emerging Science Innovation, 2024, 4: 17-32.
- [14] 李宇, 罗晶, 曾超, 等. 融合串级 PID 和虚拟模型的双足轮腿复合机器人控制[C]//第 38 届中国自动化学会青年学术年会论文集. 2023: 31-36.
- [15] Tian Yang, Shen Wentao, Zhang Qing, et al. Structure optimization and gait analysis of parallel quadruped robot[C]//ICIESR. 2021: 1212719.
- [16] Yang Jianan, Liu Yu, Zhang Jie, et al. Mobile robot navigation based on intrinsic reward mechanism with TD3 algorithm[J]. International Journal of Advanced Robotic Systems, 2024, 21(5): 17298806241292893.
- [17] He Yanxi, Qi Jie, Wu Nailong. A hybrid of RRT* and TD3 deep reinforcement learning algorithm for UAV path planning in 3D partially unknown environments[J]. Journal of Donghua University (English Edition), 2026: 1-11.
- [18] 陈建国, 姚蔚然, 孙光辉, 等. 融合进化算法和深度强化学习的飞行器制导控制一体化[J/OL]. 自动化学报, 2026. <https://kns.cnki.net/kcms2/article/abstract?v=>
- [19] JU HAO, JUAN RONGSHUN, GOMEZ RANDY, et al. Transferring policy of deep reinforcement learning from simulation to reality for robotics[J]. Nature Machine Intelligence, 2022, 4(12): 1077-1087.
- [20] Baysal Yesim A, Altas Ismail H. Deep reinforcement learning-based control of snake robot joints[J/OL]. Arabian Journal for Science and Engineering, 2025. <https://doi.org/10.1007/s13369-025-10600-4>.
- [21] LIU DONGCHEN, WANG JUNZHENG, LEI TAO, et al. Active suspension control with consensus strategy for dynamic posture tracking of wheel-legged robotic systems on uneven surfaces[J]. ISA Transactions, 2022, 131: 628-638.
- [22] Yang Zhenyi, Li Chenyi, Zhang Long. Self balancing performance of wheel-legged robots under disturbance and faulty conditions[C/OL]//IRAC. 2024: 37-44. <https://ieeexplore.ieee.org/document/10871668>.
- [23] LI MINGYING, LIU ZHILEI, WANG MANFU, et al. Design of a parallel quadruped robot based on a novel intelligent control system[J]. Applied Sciences, 2022, 12(9): 4358.
- [24] Yang Haiyang, Qin Yechen, Bai Weiqi, et al. Adaptive active compliance control for wheel-legged vehicles on uneven roads based on a parallel integrated framework[C/OL]//CVCI. 2024: 1-6. <https://ieeexplore.ieee.org/document/10871669>.
- [25] 薛文超, 胡立坤. 仿生六足机器人虚拟模型控制[J]. 计算机与数字工程, 2024, 52(1): 271-276.

作者简介

马晓爽(1992—), 女, 博士, 讲师, 专任教师。研究领域为水下导航, 信息融合。

李晨龙(1988—), 男, 博士, 副研究员。研究领域为无人系统抗干扰控制。

孙启鸣(1987—), 男, 博士, 讲师, 专任教师。研究领域为非线性控制。